

Instituto Tecnológico Superior de Ciudad Constitución

REPORTE DE CALIDAD DE DATOS.

Identificación, Análisis y Corrección de Hallazgos.

Ingeniería en Sistemas Computacionales

Ciencia de Datos.

Isaac Felipe García Lopez.

Abril de 2026

Introducción

El presente reporte documenta el proceso de auditoría de calidad sobre el dataset pipol_datos.csv, disponible en el repositorio https://github.com/lsacNM/manejo_datos. El objetivo es identificar valores atípicos (outliers), datos nulos, errores ortográficos y violaciones de integridad de dominio, así como proponer y aplicar funciones correctivas que dejen el dataset listo para análisis estadístico.

El dataset contiene información demográfica y socioeconómica. El análisis siguió el material de apoyo (Tratamiento Datos Parte 1) incluyendo el uso de z-score para outliers y funciones lambda para corrección de negativos.

Exploración Inicial del Dataset

Tras cargar el archivo con pandas se realizaron los siguientes pasos de exploración:

- Asignación del índice original con `index_col=[0]` para suprimir la columna Unnamed.
- Renombrado de columnas al inglés: age, sex, income, height, city, education, children.
- Revisión de tipos de dato (dtypes): age, income, height y children son numéricos; sex, city y education son categóricos (object).
- Conteo de valores nulos por columna.
- Extracción de valores únicos para columnas categóricas mediante `set()`.

Código de exploración inicial:

```
df = pd.read_csv(path, index_col=[0])
df.columns = ['age', 'sex', 'income', 'height', 'city', 'education', 'children']
print(df.dtypes)
print(df.isnull().sum())
print(set(df['sex']))
print(set(df['city']))
print(set(df['education']))
```

Instituto Tecnológico Superior de Ciudad Constitución

Hallazgos por Columna

Tabla de Hallazgos

Columna	Problema	# Casos	Severidad	Solución propuesta
age	Valores negativos (p.ej. -10)	~40	Alta	Reemplazar con 0 o mediana
age	Outliers imposibles (>100)	~120	Alta	Sustituir por mediana vía z-score
sex	NaN coincidentes con outliers de edad	~120	Media	Imputar con moda ('F')
income	Ingresos negativos (p.ej. -1886)	~120	Alta	Reemplazar por 0
city	NaN coincidentes con outliers de edad	~120	Media	Imputar con moda
education	'mastre' → Master	~80	Baja	Corrección ortográfica
education	'pHd' → PhD	~60	Baja	Corrección ortográfica
education	'Bachelors' → Bachelor	~70	Baja	Estandarización
education	'no education' → No Education	~50	Baja	Normalización de capitalización
children	Valores negativos (p.ej. -5)	~120	Alta	Reemplazar por 0

Instituto Tecnológico Superior de Ciudad Constitución

Detalle de Hallazgos

Columna: age (Edad)

Problema 1 – Outliers por encima del rango humano: Se encontraron valores como 150, 162, 166, 175, 183, 188, 193, 199, 200. Una edad humana máxima verificada es ~122 años. Estos valores son biológicamente imposibles y fueron detectados mediante la técnica **z-score** con umbral $|z| > 3$.

Problema 2 – Edades negativas: Valores como -1, -2, -3, -5, -7, -8, -9, -10. Una edad no puede ser negativa. Se observa que estas filas también tienen NaN en sex y city, lo que sugiere que son registros corruptos o de prueba.

Columna: sex (Género)

Valores únicos encontrados: {'F', 'M', NaN}. Los NaN corresponden exactamente a los registros con edades outlier, confirmando que son filas con datos inválidos. No hay errores tipográficos en los valores válidos.

Columna: income (Ingresos)

Valores negativos: Se detectaron ingresos negativos en los mismos registros con edades outlier (p.ej. -1886, -1172, -1788, -1481). Conforme al enunciado del problema, **no se permiten ingresos negativos**. Se reemplazarán por 0.

Columna: education (Nivel Educativo)

Valores únicos encontrados: {Bachelor, Bachelors, Master, mastre, PhD, pHd, None, no education}. Se identifican 4 problemas:

- 'mastre' — falta ortográfica de 'Master'
- 'pHd' — capitalización incorrecta de 'PhD'
- 'Bachelors' — forma plural no estándar; debe unificarse como 'Bachelor'
- 'no education' — en minúsculas, se normaliza a 'No Education'

Instituto Tecnológico Superior de Ciudad Constitución

Columna: children (Hijos)

Valores negativos: Cantidades como -5, -4, -3, -2, -1 son inválidas. El número de hijos no puede ser negativo. Se reemplazarán por 0 usando una función lambda.

Funciones de Corrección

Se desarrollaron cuatro funciones modulares que pueden aplicarse de forma independiente o encadenada:

Eliminar_negativos(df, columnas)

Reemplaza valores negativos por 0 en cualquier columna numérica indicada. Internamente usa una función anónima (lambda) por columna.

```
def eliminar_negativos(df, columnas):  
    df = df.copy()  
    for col in columnas:  
        df[col] = df[col].apply(lambda x: 0 if x < 0 else x)  
    return df
```

Aplicación: eliminar_negativos(df, ['income', 'children'])

Tratar_outliers_edad(df, columna, umbral)

Calcula el z-score de la columna de edad y reemplaza los valores cuyo z-score supera el umbral ($|z| > 3$) por la mediana de la columna. Esta es la técnica recomendada en el material de apoyo.

```
def tratar_outliers_edad(df, columna='age', umbral=3.0):  
    df = df.copy()  
    serie = df[columna].dropna()  
    z = np.abs(stats.zscore(serie))  
    idx_out = serie[z > umbral].index  
    df.loc[idx_out, columna] = serie.median()  
    return df
```

Instituto Tecnológico Superior de Ciudad Constitución

Corregir_educacion(df, columna, mapa)

Normaliza los valores de la columna de educación aplicando un diccionario de sustitución. Admite cualquier mapa personalizado.

```
MAPA_EDUCACION = {
    'mastre' : 'Master',
    'pHd' : 'PhD',
    'Bachelors' : 'Bachelor',
    'no education' : 'No Education',
}

def corregir_educacion(df, columna='education', mapa=MAPA_EDUCACION):
    df = df.copy()
    for incorrecto, correcto in mapa.items():
        df.loc[df[columna] == incorrecto, columna] = correcto
    return df
```

Rellenar_nulos_moda(df, columnas)

Imputa valores NaN en columnas categóricas con la moda (valor más frecuente) de cada columna. Apropiado cuando la distribución de valores válidos es sesgada.

```
def rellenar_nulos_moda(df, columnas):
    df = df.copy()
    for col in columnas:
        moda = df[col].mode()[0]
        df[col].fillna(moda, inplace=True)
    return df
```

Pipeline de Limpieza y Resultados

Las cuatro funciones se aplican en secuencia formando un pipeline reproducible:

```
df_clean = df.copy()
df_clean = eliminar_negativos(df_clean, ['income', 'children'])
df_clean = tratar_outliers_edad(df_clean, 'age')
df_clean = corregir_educacion(df_clean)
df_clean = rellenar_nulos_moda(df_clean, ['sex', 'city'])
```


Instituto Tecnológico Superior de Ciudad Constitución

Resultados del pipeline:

Función aplicada	Columna(s)	Registros afectados	Estado final
eliminar_negativos	income, children	~120 + ~120	Sin negativos
tratar_outliers_edad	age	~120 outliers	Reemplazados por mediana
corregir_educacion	education	~260 registros	4 formas normalizadas
rellenar_nulos_moda	sex, city	~120 NaN c/u	Sin nulos

Conclusiones y recomendaciones.

El análisis de integridad sobre pipol_datos.csv reveló problemas en cuatro de las siete columnas del dataset. Los hallazgos más críticos fueron:

- Aproximadamente 120 registros presentan valores imposibles en age, income, children y NaN en sex/city de forma simultánea, lo que sugiere que son filas corruptas o generadas sintéticamente con errores.
- La columna education contenía cuatro variantes ortográficas del mismo conjunto de categorías, lo que habría impedido un agrupamiento correcto.
- Los ingresos negativos, aunque podrían interpretarse como deudas en otro contexto, se tratan como inválidos según los requerimientos del problema.

Recomendaciones adicionales:

- Considerar eliminar los registros con edad outlier en lugar de imputar, si el dataset es suficientemente grande.
- Aplicar ndiff para comparar versiones del dataset antes y después de la limpieza.
- Establecer un esquema de validación (rangos permitidos, catálogos) para prevenir la entrada de datos inválidos en origen.
- Documentar cada transformación con metadatos de auditoría (fecha, función, registros afectados).

Bibliografía

Repositorio del proyecto: https://github.com/lsacNM/manejo_datos

Material de apoyo: Tratamiento Datos Parte 1 (apoyo1.txt)

McKinney, W. (2022). Python for Data Analysis, 3rd ed. O'Reilly Media.

pandas Documentation – v2.x. <https://pandas.pydata.org/docs/>

SciPy Documentation – stats.zscore. <https://docs.scipy.org/doc/scipy/>

NumPy Documentation – numpy.abs. <https://numpy.org/doc/stable/>